

UNIVERSITÄT

BONN

AIS

COMPUTATIONAL INTELLIGENCE

10. FUZZY LOGIC

Prof. Dr. Sven Behnke

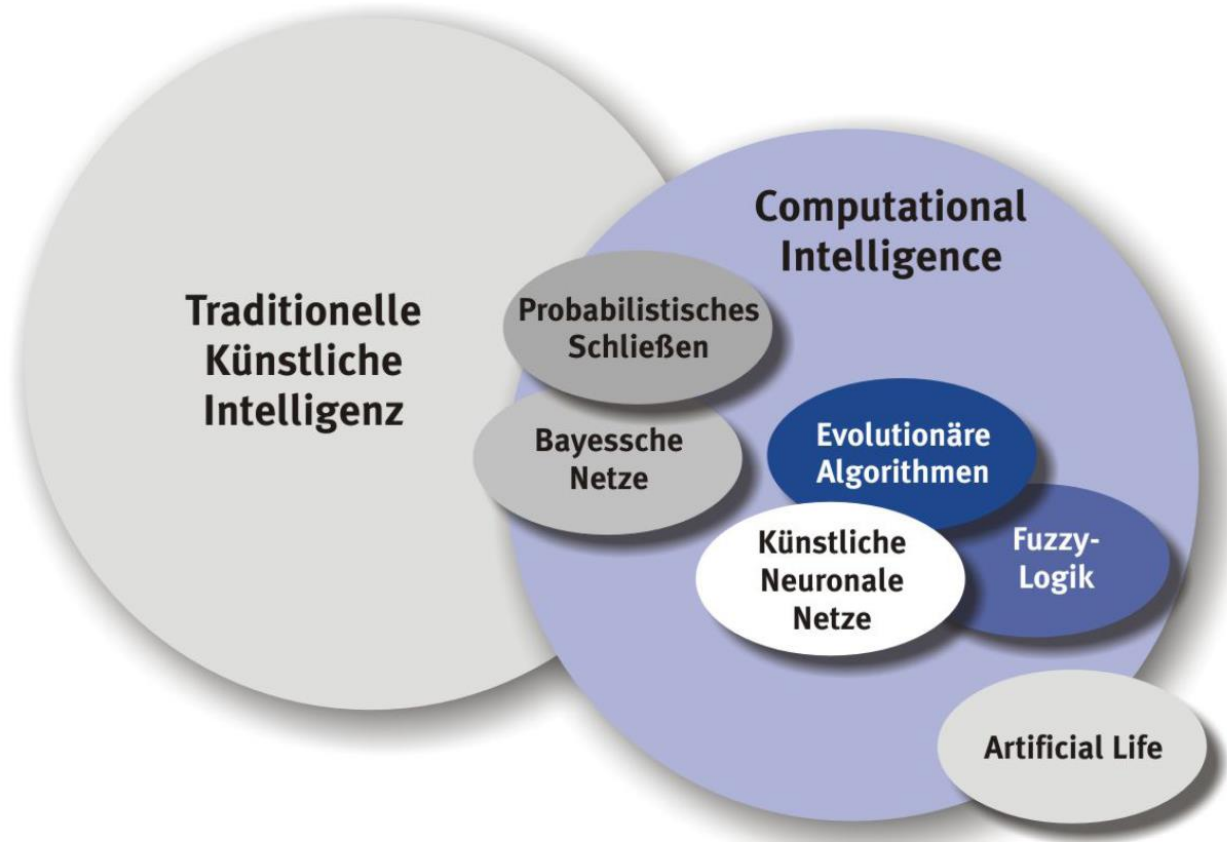
KLAUSUR

- 20. Juli ~~15:00-17:00~~ im ~~HS 1+2~~ (~~Hörsaalzentrum, Endenicher Allee 19c~~)

Geändert: 12:00-14:00 im Wolfgang Paul-Hörsaal, Kreuzbergweg 28

- 90 Minuten Bearbeitungszeit
- Closed Book

BAUSTEINE DER COMPUTATIONAL INTELLIGENCE



MOTIVATION

- Entwickelt von Lotfi Zadeh seit 1965



- Modellierung unscharfer Konzepte:
 - Bsp: Alter, Gewicht, Größe, ...
- Modellierung unscharfer Abhängigkeiten (z.B. Regeln):
 - Wenn die Temperatur niedrig ist und Öl wenig kostet, drehe die Heizung auf
- Herkunft der Information:
 - Modellierung von Expertenwissen
 - Repräsentation von Informationen, die aus inhärent ungenauen Daten extrahiert wurden

CHARAKTERISTISCHE FUNKTIONEN KLASSISCHER (SCHARFER) MENGEN


- Klassische Mengen können durch eine charakteristische Funktion beschrieben werden:

$$m_A(x) := \begin{cases} 1 & x \in A \\ 0 & x \notin A \end{cases}$$

$$m_A(x) \in \{0,1\}$$

- Beispiel:

$$A = \{x \mid a \leq x \leq b\}$$




CHARAKTERISTISCHE FUNKTIONEN VON FUZZY-MENGEN

- Fuzzy-Mengen werden durch eine Mitgliedschaftsfunktion beschrieben:

$$\mu_{\tilde{A}}(x) \in [0,1]$$

- Beispiel: $\tilde{A} = x \text{ is roughly in } [a, b]$




LINGUISTISCHE VARIABLEN UND WERTE

■ Zuschreibung von **Semantik** zu Fuzzy-Mengen


- **Linguistische Variablen**: Domäne der Fuzzy-Mengen
- **Linguistische Werte**: „Diskretisierung“ dieser Domäne durch Fuzzy-Mengen

■ Bsp:

- Age: young, old




- Size: small, medium, tall




LINGUISTISCHE WERTE UND KONTEXT

■ Basketball-Spieler:




■ Jockeys:




➔ Linguistische Werte sind kontextabhängig!

BELIEBTE MITGLIEDSCHAFTSFUNKTIONEN


■ Trapezoid $\langle a, b, c, d \rangle$




■ Gaußglocke $N(m, s)$



■ Dreieck $\langle a, b, d \rangle$




■ Diskrete Werte $\{(a, 1), (b, 0.5)\}$



FUZZY-MITGLIEDSCHAFTSFUNKTIONEN: GRUNDLEGENDE BEGRIFFE

- **Support:** Menge mit Mitgliedschaft $\mu(x) > 0$
- **Core:** Menge mit Mitgliedschaft $\mu(x) = 1$
- **α -cut:** Menge mit Mitgliedschaft $\mu(x) \geq \alpha$
- **Height:** Maximale Mitgliedschaft




OPERATOREN AUF FUZZY-MENGEN: KONJUNKTION (UND)

- Menge von Personen, die sowohl alt als auch groß sind (Konjunktion)

$$\mu_{\text{old}}(x) = 0.7$$

$$\mu_{\text{tall}}(x) = 0.5$$

$$\mu_{\text{old} \wedge \text{tall}}(x) = ? \quad \mu_{\text{old} \wedge \text{tall}}(x) = 0.5$$



**Grenzfälle der
Booleschen Logik
müssen weiterhin
gelten!**


OPERATOREN AUF FUZZY-MENGEN: DISJUNKTION (ODER)

- Menge von Personen, die alt oder groß sind (Disjunktion)

$$\mu_{\text{old}}(x) = 0.7$$

$$\mu_{\text{tall}}(x) = 0.5$$


$$\mu_{\text{old} \vee \text{tall}}(x) = ?$$



OPERATOREN: MIN/MAX - NORM

■ Klassische Fuzzy-Operatoren: Min/Max-Norm


- Konjunktion: $\mu_{A \wedge B}(x) := \min\{\mu_A(x), \mu_B(x)\}$



OPERATOREN: MIN/MAX - NORM

■ Klassische Fuzzy-Operatoren: Min/Max-Norm


- Konjunktion: $\mu_{A \wedge B}(x) := \min\{\mu_A(x), \mu_B(x)\}$
- Disjunktion: $\mu_{A \vee B}(x) := \max\{\mu_A(x), \mu_B(x)\}$



OPERATOREN: MIN/MAX - NORM

■ Klassische Fuzzy-Operatoren: Min/Max-Norm

- Konjunktion: $\mu_{A \wedge B}(x) := \min\{\mu_A(x), \mu_B(x)\}$
- Disjunktion: $\mu_{A \vee B}(x) := \max\{\mu_A(x), \mu_B(x)\}$
- Negation: $\mu_{\neg A}(x) := 1 - \mu_A(x)$



T-NORM UND S-NORM

- Operatoren für Konjunktion (T-Norm) und Disjunktion (S-Norm) müssen zueinander passen
- Können mit De Morganscher Regel ineinander überführt werden:

$$(A \wedge B = \neg(\neg A \vee \neg B))$$

$$S(u,v) = 1 - T(1-u, 1-v)$$

$$T(u,v) = 1 - S(1-u, 1-v)$$

- Beispiel Min/Max-Norm:


$$\max(u,v) = 1 - \min(1-u, 1-v)$$

$$\dots = 1 - 1 - \min(-u, -v) = \max(u,v)$$

FUZZY T- UND S-NORMEN


T-Norm

$$T(a,b) = \min\{a,b\}$$




S-Norm

$$S(a,b) = \max\{a,b\}$$




Min-Max

$$T(a,b) = a \cdot b$$



Product-Sum


$$S(a,b) = a + b - a \cdot b$$



EXTREME FUZZY T- UND S-NORMEN

T-Norm


$$T(a, b) = \max\{0, a + b - 1\}$$




Lukasiewicz
Norm

S-Norm

$$S(a, b) = \min\{1, a + b\}$$




$$T(a, b) = \begin{cases} a & , \text{if } b = 1 \\ b & , \text{if } a = 1 \\ 0 & , \text{else} \end{cases}$$



Drastic
Product/Sum


$$S(a, b) = \begin{cases} a & , \text{if } b = 0 \\ b & , \text{if } a = 0 \\ 1 & , \text{else} \end{cases}$$



OPERATOR-SPEKTRUM

■ T-Norm

■ T-Konorm (S-Norm)




- Es gibt unterschiedlich extreme Operatoren
- T-Norm und S-Norm müssen zusammen passen


FUZZY NORMEN: PROBLEME

- Interessante Effekte:

– $A \wedge \neg A = ?$



– $A \vee \neg A = ?$



MITGLIEDSCHAFT VS. WAHRSCHEINLICHKEIT

■ Wahrscheinlichkeit:

- Häufigkeit von Zufallsereignissen

■ Mitgliedschaft:

- Grad der Zugehörigkeit zu einem Konzept

- Bsp: Krankheitswahrscheinlichkeit vs.
Grad der Zugehörigkeit zu den Kranken

FUZZY-IMPLIKATION

■ Eine Möglichkeit:

- Ableitung von Tautologie $A \rightarrow B = \neg A \vee (A \wedge B)$
und Min/Max-Norm

$$\mu_{A \rightarrow B}(x) := \max \left\{ \underbrace{1 - \mu_A(x)}_{*V*}, \underbrace{\min\{\mu_A(x), \mu_B(x)\}}_{A \wedge B} \right\}$$

FUZZY-IMPLIKATION

■ Oder umgekehrt:

- Starte mit Lukasiewicz-Implikation

$$\mu_{A \rightarrow B}(x) := \min\{1, 1 - \mu_A(x) + \mu_B(x)\}$$

und leite Lukasiewicz-Disjunktion und -Konjunktion ab

- $A \vee B = \neg A \rightarrow B$

$$\mu_{A \vee B}(x) := \min\{1, \mu_A(x) + \mu_B(x)\}$$

- $A \wedge B = \neg (\neg A \vee \neg B)$ // de Morgan

$$\begin{aligned}\mu_{A \wedge B}(x) &:= 1 - \min\{1, 1 - \mu_A(x) + 1 - \mu_B(x)\} \quad // \text{ mit Lukasiewicz-Disjunktion} \\ &= \max\{0, \mu_A(x) + \mu_B(x) - 1\}\end{aligned}$$

FUZZY-FOLGERUNGEN

■ Klassischer Modus Ponens:

$$\frac{A \quad A \rightarrow B}{B}$$

$$\frac{\neg A \quad A \rightarrow B}{?}$$

■ Fuzzy: Generalisierter Modus Ponens



$$\frac{\mu_{A'}(x) \quad A \rightarrow B}{\mu_{B'}(y)}$$

GEMEINSAMER CONSTRAINT: SUPPORT-VERTEILUNG

- Mit Min/Max-Norm führt Implikation $A \rightarrow B$ zu Einschränkungen des Kartesischen Produkts $A \times B$

$$\mu_{A \times B}(x, y) = \min\{\mu_A(x), \mu_B(y)\}$$

$$\mu_{B'}(y) = \sup_x \{\min\{\mu_{A'}(x), \mu_{A \times B}(x, y)\}\}$$



FUZZY-REGELN

- Regel:

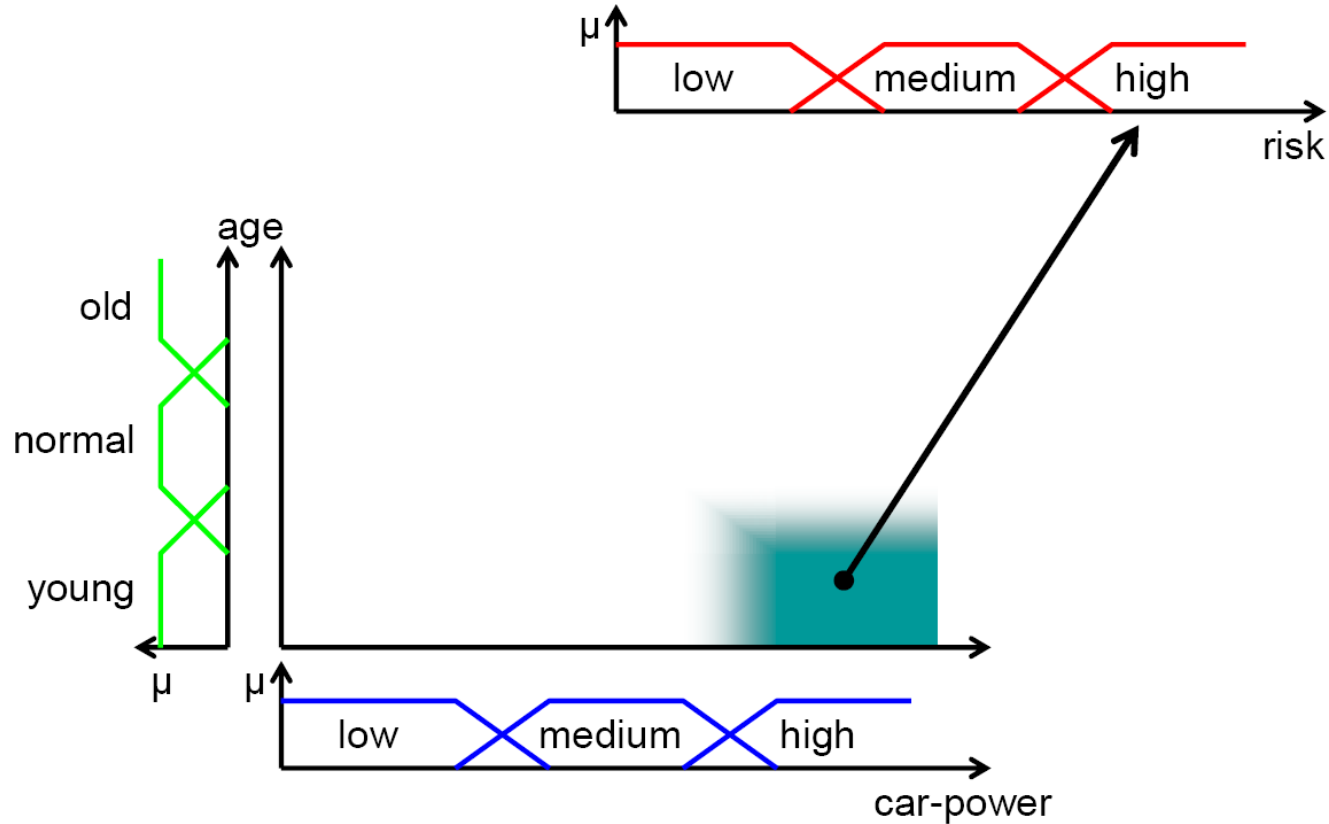
IF <Prämisse> THEN <Konklusion>

- Fuzzy-Version 1: Mamdani-Regeln

- Prämisse: Konjunktion (Und) von Fuzzy-Mitgliedschaften
- Konklusion: Fuzzy-Menge

BEISPIEL: MAMDANI-REGEL

IF age IS young AND car-power IS high THEN risk IS high



FUZZY-REGELN

- Regel:

IF <Prämisse> THEN <Konklusion>

- Fuzzy-Version 1: Mamdani-Regeln

- Prämisse: Konjunktion (Und) von Fuzzy-Mitgliedschaften
- Konklusion: Fuzzy-Menge


- Fuzzy-Version 2: Takagi-Sugeno-Regeln

- Prämisse: Konjunktion (Und) von Fuzzy-Mitgliedschaften
- Konklusion: (normalerweise) reellwertige Funktion vom Grad 0-2.

BEISPIEL: TAKAGI-SUGENO-REGEL

IF age IS young AND car-power IS high



THEN risk-factor = $w_0 + w_1 \cdot \text{age} + w_2 \cdot \text{car-power}$




FUZZY-REGELSYSTEM

R1: IF age IS young AND car-power IS high THEN risk IS high

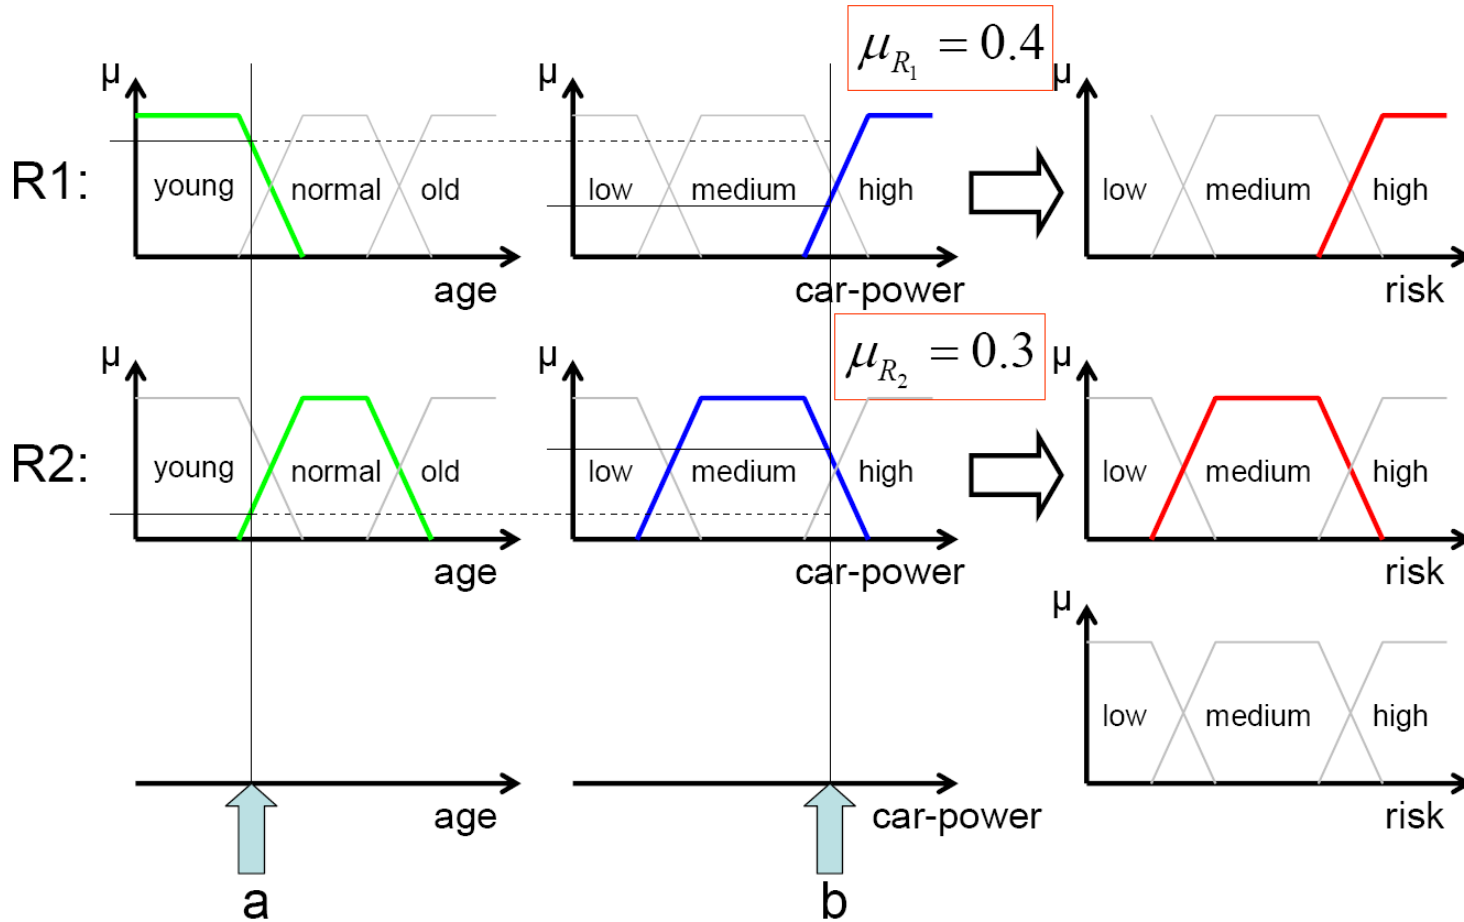
R2: IF age IS normal AND car-power IS medium THEN risk IS medium



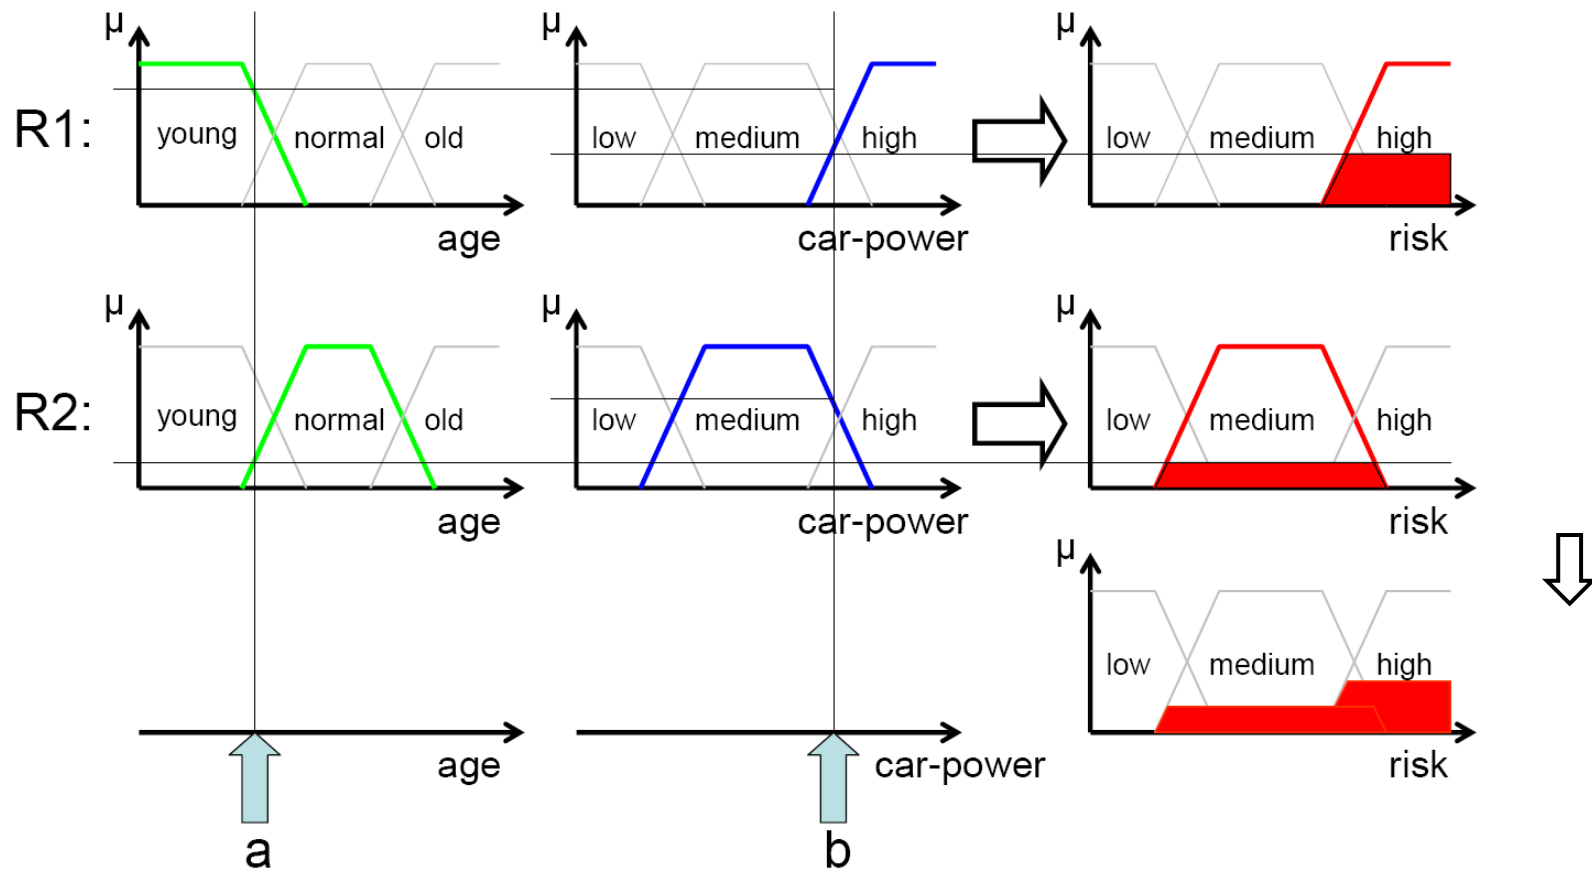
FUZZYFIZIERUNG SCHARFER EINGABEN




INFERENZ (Z.B. VIA MIN/MAX-NORM)



INFERENZ (Z.B. VIA MIN/MAX-NORM)



DEFUZZYFIZIERUNG



DEFUZZYFIZIERUNG

- Schwerpunkt:

$$y = \frac{\int y \cdot \mu_{\text{risk}}(y) dy}{\int \mu_{\text{risk}}(y) dy}$$


- Approximation: Gewichtete Summe der einzelnen Ausgabe-Fuzzymengen

$$y = \frac{\sum_{j=1}^r \mu_j \cdot s_j}{\sum_{j=1}^r \mu_j}$$

Aktivierung der Regel j


Schwerpunkt der Ausgabe-Fuzzymenge j

FUZZY INFERENCE (MAMDANI)



Fuzzy Rules

if temp is cold then valve is open	$\mu_{\text{cold}} = 0.7$
if temp is warm then valve is half	$\mu_{\text{warm}} = 0.2$
if temp is hot then valve is close	$\mu_{\text{hot}} = 0.0$




FUZZY-REGELSYSTEM (MAMDANI)

R1: if x is small then y is medium

R2: if x is medium then y is large


R3: if x is large then y is zero



FUZZY-REGELSYSTEM (TAKAGI-SUGENO)

- R1: IF x IS small THEN y = x
R2: IF x IS medium THEN y = 5
R3: IF x IS large THEN y = 2*x-5

$$y = \frac{\sum_{i=1}^r \mu_{R_i} \cdot y_i(\vec{x})}{\sum_{i=1}^r \mu_{R_i}}$$




KONSTRUKTION VON FUZZY-REGELSYSTEMEN

WANG & MENDEL - ALGORITHMUS


- Gegeben: Menge von Beispielen, vordefinierte Fuzzy-Mengen
- Beispiele mit höchster Mitgliedschaft bestimmen die Ausgabe

R1: if x is zero then y is medium
R2: if x is small then y is medium
R3: if x is medium then y is large
R4: if x is large then y is medium




- Exponentiell viele Regeln in hochdimensionalen Räumen
- Beliebige gute Approximation wenn Grid-Auflösung fein genug (aber zu welchen Kosten!)
- Falsche Wahl des Grids kann Extrema verpassen

HIGGINS & GOODMAN - ALGORITHMUS



- Starte mit nur einer Mitgliedschaftsfunktion
- Füge neue ein wo der Fehler am größten ist
- Vordefinierter Schwellwert für erwünschten Approximationsfehler
- Findet "beste" Partitionierung (=Grid)




- Nachteile:
 - Konzentration auf Outlier
 - Interpretation schwierig: Granularität hängt nur von Daten ab

ANDERE KONSTRUKTIVE ALGORITHMEN

- Lokale Mitgliedschaftsfunktionen
- Teilweise vordefinierte Mitgliedschaftsfunktionen/Granularitäten möglich
- Teilweise Toleranz gegen Outlier durch Relevanz-Filter

FREIE FUZZY-REGELN



- Keine globale Granularität:
 - Individuelle (pro Regel) Mitgliedschafts-Funktionen
 - Bessere Modellierung lokaler Eigenschaften
- Nicht alle Attribute in jeder Regel verwendet:
 - Individuelle Auswahl der Prämisse durch Beschränkung auf wenige Attribute
 - Bessere Interpretierbarkeit in hochdimensionalen Räumen
 - Kein exponentielles Wachstum der Regelanzahl mit der Dimensionalität

ERZEUGUNG FREIER FUZZY-REGELN

- Ziel: Klassifikation des Eingaberaums entsprechend Trainingsmenge $\{(x_i, c_i)\}$

Algorithmus FRL zur Klassifikation:

FORALL training examples (\mathbf{x}, c) DO

IF correct rule of class c exists:

- COVERED:
 - increase weight +1
 - adjust core region of rule to cover \mathbf{x}


ELSE:

- COMMIT:
 - insert new rule with core= \mathbf{x}
 - Support = infinite (i.e. rule is not constrained)

SHRINK:


- Reduce support of all rules of conflicting class that cover \mathbf{x} (e.g. try to keep largest volume).

Until no more changes occurred.




BEISPIEL: FUZZY-KLASSIFIKATOR



commit




covered




covered



commit, shrink



covered, shrink



covered, shrink

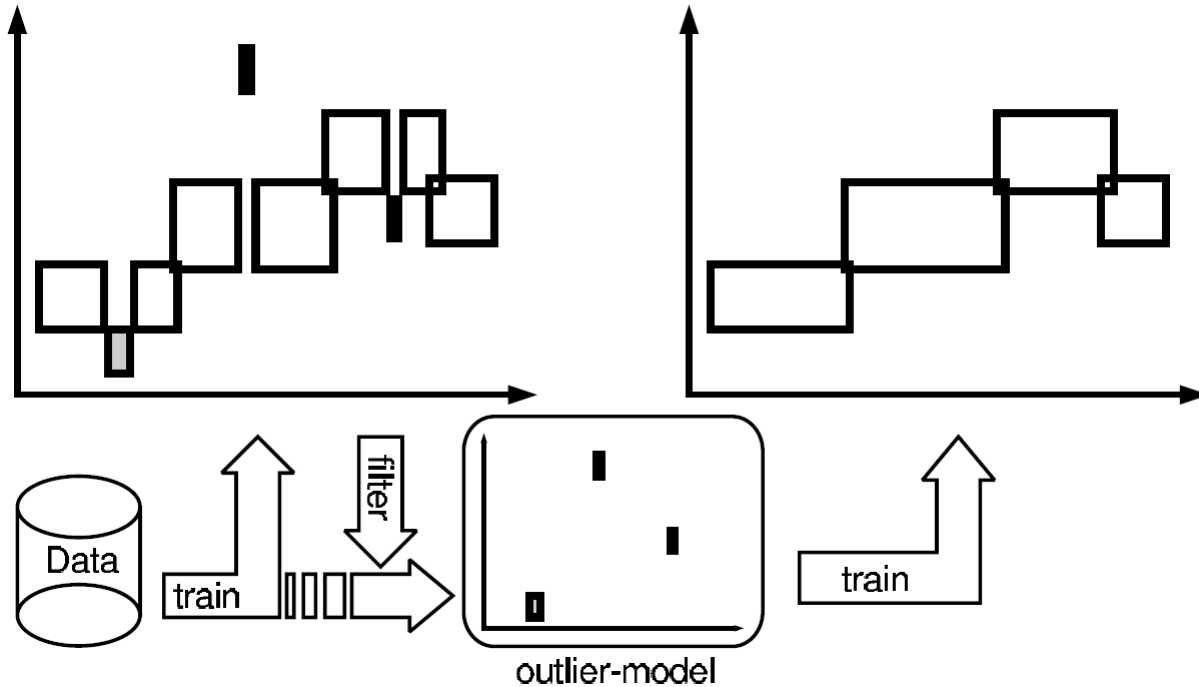
ERZEUGUNG FREIER FUZZY-REGELN

Beobachtungen:

- FRL findet Regelmengen, die die Daten vollständig beschreibt (wenn Daten ohne Konflikte sind ...)
- Jede Regel ist eine *partielle Hypothese für eine Teilmenge der Trainingsdaten*
 - **Core**: Am meisten spezifische Hypothese, die eine Teilmenge der Daten abdeckt
 - **Support**: eine der generellsten Hypothesen, die eine Teilmenge der Daten abdeckt
 - Support **is_more_general_than** Core.
- Core und Support-Regionen können interpretiert werden als:
 - Kleinstes Gebiet mit höchster Konfidenz (Wir haben Evidenz)
 - Größtes Gebiet ohne Konflikte (Wir haben noch keine Gegenbeispiele gesehen)

OUTLIER-FILTER

- Problem: Verrauschte Daten erzeugen viele Regeln mit wenigen Datenpunkten
- Ansatz: Entferne Datenpunkte, die von Regeln mit geringem Gewicht beschrieben werden und trainiere erneut



ANDERE FUZZY-LERNMETHODEN

■ Konstruktive Methoden:

- Erzeuge Fuzzy-Regeln durch Wachstum aus Singleton-Regeln
- FRL verkleinert Regeln ausgehend von den generellsten Regeln, bis diese zu den Daten passen

■ GRID-basierte Methoden:

- Verschmelze Gridzellen (oder Zeilen/Spalten) wenn keine Datenpunkte enthalten sind oder dieselbe Klasse vorhergesagt wird

■ Adaptive Methoden:

- Initialisiere Regeln zufällig (oder mit Expertenwissen) und optimiere Regel-Parameter (Orte, manchmal auch die Anzahl der Mitgliedschaftsfunktionen) iterativ (Gradientenabstieg, heuristische Optimierung wie z.B. Hill Climbing).

■ Neuro-Fuzzy-Methoden:

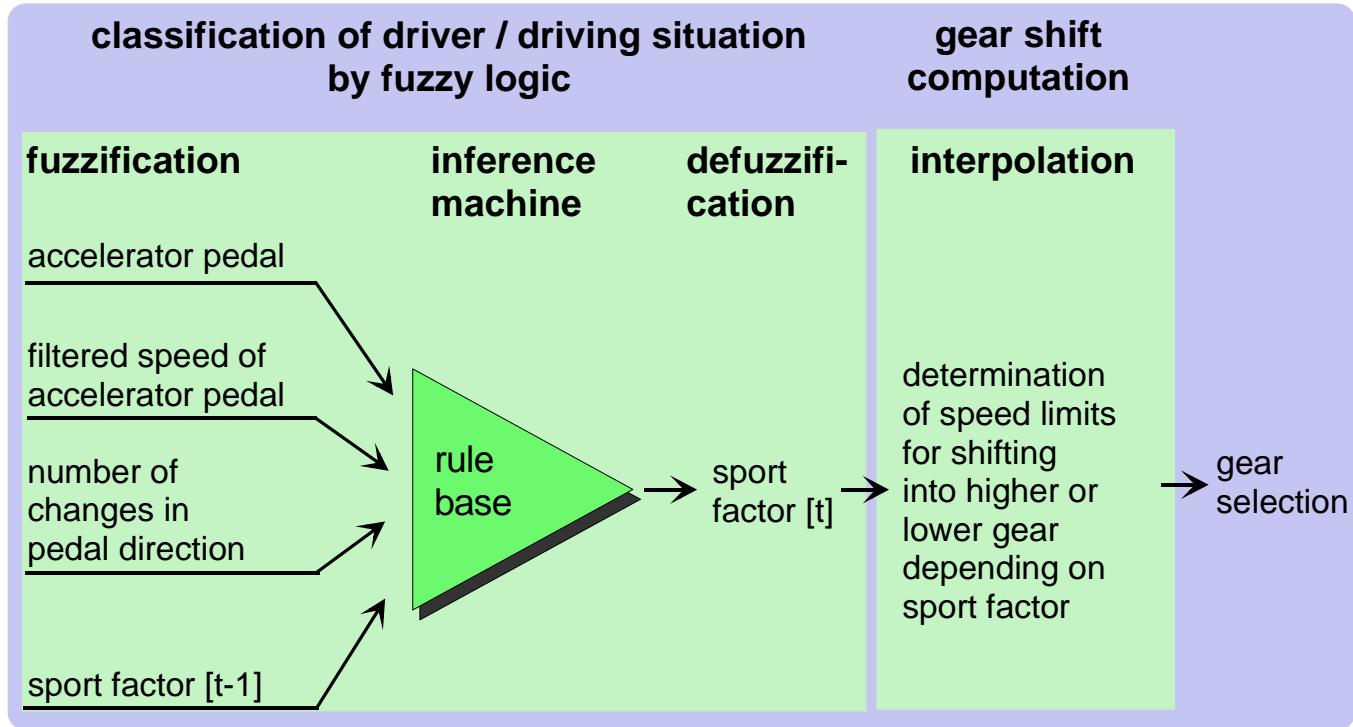
- Initialisiere neuronales Netz mit den Regeln und trainiere dieses mit Backpropagation

BEISPIEL: AUTOMATIK-GETRIEBE

- Aufgabe: Verbesserung des VW-Automatik-Getriebes
 - Keine zusätzlichen Sensoren
 - Individuelle Anpassung des Schaltverhaltens
- Idee (1995):
 - Das Fahrzeug “beobachtet” und klassifiziert den Fahrer nach Sportlichkeit
 - ruhig, normal, sportlich => Bestimmung eines Sport-Faktors aus [0, 1]
 - nervös => Beruhigung des Fahrers
- Datenerfassung im Testfahrzeug:
 - Verschiedene Fahrer, Klassifikation durch Experten (Mitfahrer)
 - Gleichzeitige Messungen:
 - Geschwindigkeit,
 - Position,
 - Geschwindigkeit des Gaspedals,
 - Winkel des Lenkrades, ...


BEISPIEL : AUTOMATIK-GETRIEBE

■ Überblick über das Gesamtsystem




FUZZY-INFERENZ

If X is **positive small** and Y is **positive small** then Z is **positive small**



If X is **positive big** and Y is **positive small** then Z is **positive big**



Eingabewerte: x und y

Stellwert: z

defuzzifizierter Wert

ERGEBNIS: ADAPTIVES SCHALTVERHALTEN

- Fuzzy-Regler mit 7 Regeln
- Optimiertes Programm
 - 24 Byte RAM
 - 702 Byte ROMauf Digimat
- Laufzeit 80 ms,
12 mal pro Sekunde wurde ein neuer Sportfaktor bestimmt
- In Serie im VW Konzern
- Erlernen von Regelsystemen mit Hilfe von Künstlichen Neuronen Netzen, Optimierung mit evolutionären Algorithmen

