

UNIVERSITÄT

BONN

AIS


COMPUTATIONAL INTELLIGENCE

11. FUZZY-ARITHMETIK, GRAFISCHE MODELLE


Prof. Dr. Sven Behnke

LETZTE VORLESUNG

■ Fuzzy-Mengen beschrieben durch Mitgliedschaftsfunktion




■ Linguistische Variablen und Werte



■ Operatoren auf Fuzzy-Mengen

- Konjunktion (z.B. min)
- Disjunktion (z.B. max)
- Negation ($1 - \mu_A(x)$)





■ Fuzzy-Implikation: $$\mu_{A \rightarrow B}(x) := \max_{*} \{ \underbrace{1 - \mu_A(x)}_{\neg A}, \underbrace{\min\{\mu_A(x), \mu_B(x)\}}_{A \wedge B} \}$$

■ Fuzzy-Regeln:

- IF <Prämisse> THEN <Konklusion>
 - Version 1 (Mamdani): Prämisse Konjunktion, Konklusion Fuzzy-Menge
 - Version 2 (Takagi-Sugeno): Prämisse Konjunktion, Konklusion einfache reelle Funktion


■ Fuzzy-Regelsystem:

- Fuzzyfizierung der Eingaben
- Aktivierungen der Prämissen
- Kombination der Konklusionen
- Defuzzyfizierung



Fuzzy Rules

if temp is cold then valve is open	$\mu_{\text{cold}} = 0.7$
if temp is warm then valve is half	$\mu_{\text{warm}} = 0.2$
if temp is hot then valve is close	$\mu_{\text{hot}} = 0.0$




FUZZY-ZAHLEN: MOTIVATION

- Häufig ist es erwünscht, ungenaue Eingaben vorzuverarbeiten
 - Addition und Multiplikation von Fuzzy-Zahlen
 - Anwendung von Funktionen (Normalisierung, ...) auf Fuzzy-Zahlen
- Fuzzy-Regler können erweitert werden, ungenaue Eingaben in Form von Fuzzy-Zahlen zu akzeptieren
- Fuzzy-Zahlen: Modelliere z.B. Mess-Ungenauigkeit

FUZZY-ZAHLEN


■ Klassische “scharfe” Zahlen: $a \in \mathbb{R}$

- Charakteristische Funktion $m_a(x) \in \{0,1\}$



■ Fuzzy-Zahlen (“ungefähr a ”):

- Mitgliedschafts-Funktion $\mu_a(x) \in [0,1]$




Mitgliedschafts-Funktionen von Fuzzy-Zahlen sind (üblicherweise):

- **Normalisiert**
- **Monoton** (links/rechts)
- **stückweise ableitbar**
- **genau an einer Stelle 1**

OPERATIONEN AUF FUZZY-ZAHLEN

■ Addition zweier scharfer Zahlen:




$$m_{a+b}(z) = \begin{cases} 1 & z = a + b \\ 0 & \text{else} \end{cases}$$

$$m_{a+b}(z) = \max_{x,y \in \mathbb{R}} \{ m_a(x) \odot m_b(y) \mid x + y = z \}$$

↑
= "and"?...

OPERATIONEN AUF FUZZY-ZAHLEN

■ Addition zweier Singletons:




$$\mu_{a+b}(z) = \begin{cases} \min\{\mu_a(a), \mu_b(b)\} & z = a + b \\ 0 & \text{else} \end{cases}$$

$$\mu_{a+b}(z) = \max_{x,y \in \mathbb{R}} \underbrace{\{\min\{\mu_a(x), \mu_b(y)\} \mid x + y = z\}}_{= \text{and}}$$


ADDITION ZWEIER FUZZY-INTERVALLE

■ Intervall-Arithmetik




$$\mu_{a+b}(z) = \max_{x,y \in \mathbb{R}} \underbrace{\min\{\mu_a(x), \mu_b(y)\}}_{= \text{and}} \mid x + y = z$$

ADDITION ZWEIER FUZZY-ZAHLEN



$$\mu_{a+b}(z) = \max_{x,y \in \mathbb{R}} \{ \min \{ \mu_a(x), \mu_b(y) \} \mid x + y = z \}$$


MULTIPLIKATION ZWEIER FUZZY-ZAHLEN



$$\mu_{a*b}(z) = \max_{x,y \in \mathbb{R}} \{ \min \{ \mu_a(x), \mu_b(y) \} \mid x * y = z \}$$


ANWENDUNG SCHARFER FUNKTIONEN AUF FUZZY-ZAHLEN

$$\mu_{f(a)}(y) = \max_{x \in R} \{ \mu_a(x) \mid y = f(x) \}$$



ANWENDUNG NICHTMONOTONER FUNKTIONEN AUF FUZZY-ZAHLEN

$$\mu_{f(a)}(y) = \max_{x \in R} \{ \mu_a(x) \mid y = f(x) \}$$



ANWENDUNG VON FUNKTIONEN MIT MEHREREN EINGABEN


- Nach Erweiterungsprinzip:

$$\mu_{f(a)}(y) = \max_{x_1, \dots, x_n \in R} \left\{ \min \left\{ \mu_{a_1}(x_1), \dots, \mu_{a_n}(x_n) \right\} \mid y = f(x_1, \dots, x_n) \right\}$$


- Berechnung des Maximums unpraktisch
- Approximative Berechnung:
 - Folge von α -Cuts → Rückführung auf Intervall-Arithmetik
 - Polynomielle Repräsentation der linken und der rechten Seite von Fuzzy-Zahlen (abgeschlossen unter Addition und Multiplikation)
 - Diskretisierung der Variablen (Grid-basiert)
 - ...

FUZZY-FUNKTIONEN (FUZZY-GRAPHEN)


- Reellwertige Funktionen: Unendliche Menge scharfer Punkte
- Fuzzy-Graph: Endliche Menge ungenauer Punkte
 - IF x IS small THEN y IS medium
 - IF x IS medium THEN y IS small
 - IF x IS large THEN y IS large



FUZZY-GRAPH: BEISPIEL



FUZZY-GRAPH: BEISPIEL



FUZZY-FUNKTIONEN (FUZZY-GRAPHEN)

- Jeder Fuzzy-Punkt beschreibt eine ungenaue Relation:

$$(\vec{x}, y) \text{ IS } \mathbf{A} \times B$$

- Ein Fuzzy-Graph ist eine Menge von Fuzzy-Punkten:

$$(\vec{x}, y) \text{ IS } \mathbf{A}_1 \times B_1 \text{ OR } \dots \text{ OR } \mathbf{A}_r \times B_r$$

- Inferenz mit
Fuzzy-Graphen:

$$\vec{x} \text{ IS } \mathbf{A}$$


$$\tilde{f} \text{ IS } \bigcup_{j=1}^r \mathbf{A}_j \times B_j$$

$$y \text{ IS } B$$

BERECHNUNG VON FUZZY-GRAPHEN

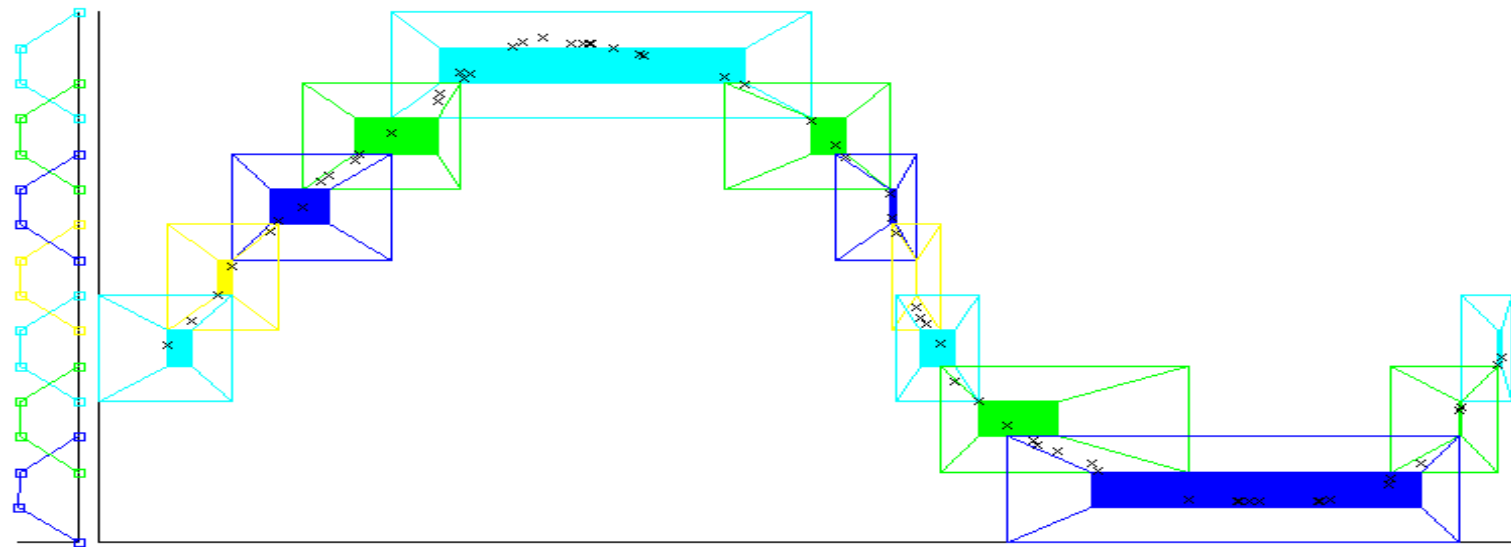
- Projektion von Schnitt mit zylindrischer Erweiterung:

$$B = \text{proj}_y \left\{ (\mathbf{A} \times I) \cap \tilde{f} \right\}$$




GRANULARITÄT VON FUZZY-GRAPHEN

■ Fein granular



GRANULARITÄT VON FUZZY-GRAPHEN

■ Grob granular



ZUSAMMENFASSUNG

■ Fuzzy-Methoden

- Modellierung unsicheren Wissens (Fuzzy-Regeln)
- Inferenz berücksichtigt Ungenauigkeiten

■ Wesentliche Konzepte:

- Fuzzy-Mengen und Grad der Mitgliedschaft
- Operatoren auf Fuzzy-Mengen
- Erweiterungsprinzip: Anwendung klassischer Funktionen auf Fuzzy-Zahlen

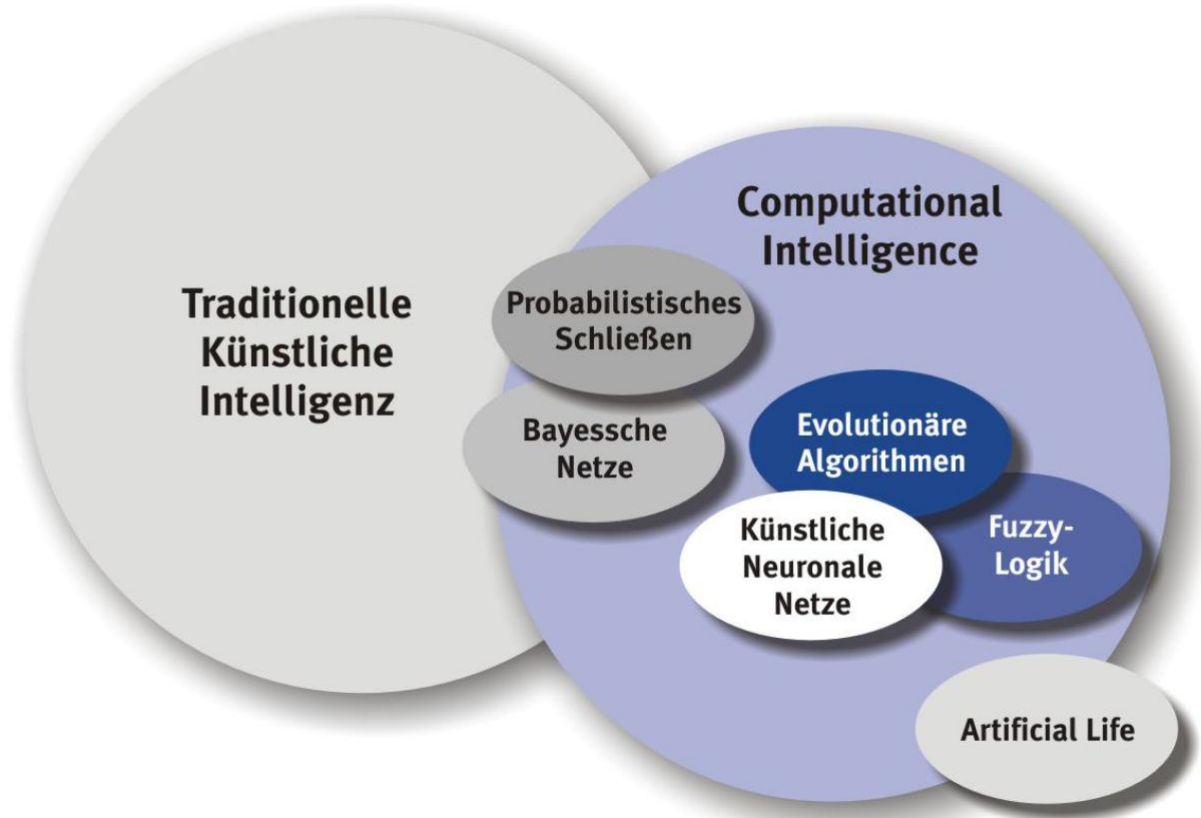
■ Algorithmen (meist heuristisch) für:

- Erzeugung von Fuzzy-Regeln aus Daten
- Lernen von Fuzzy-Approximatoren (Fuzzy-Graphen/Regelsysteme)

■ Fuzzy-Regler haben weite Anwendung gefunden

- Reiskocher
- Kameras
- Waschmaschinen
- Automatik-Getriebe

BAUSTEINE DER COMPUTATIONAL INTELLIGENCE



PROBABILISTISCHE GRAFISCHE MODELLE

Beispiel für das Rechnen mit Wahrscheinlichkeiten

■ Gegeben:


- Zwei Eimer mit je zwei Bällen rot/blau
- 100€ Belohnung bei Ziehen des einzigen roten Balls
- Zufällige Wahl des Eimers
- Zufälliges Ziehen eines Balls => Dieser ist blau

■ Jetzt darf man den Eimer wechseln und noch einmal ziehen.
Ist das Wechseln vorteilhaft?

■ Zufallsvariablen


- Gewählter Eimer: $E \in \{1, 0\}$
- Farbe des Balls: $B \in \{r, b\}$
- Zufällige Eimerwahl: $P(E = 1) = P(E = 0) = 1/2$
- Ballverteilung: $P(B = r \mid E = 1) = 1/2$. $P(B = r \mid E = 0) = 0$
- Frage: $P(E = 1 \mid B = b) \geq 1/2$? // Falls ja, sollten wir nicht wechseln.

$$P(E = 1 \mid B = b) = \frac{P(B=b|E=1)P(E=1)}{P(B=b)} = \frac{1/2 \cdot 1/2}{3/4} = 1/3 \quad \Rightarrow \text{Wechseln!}$$



MOTIVATION FÜR PROBABILISTISCHE GRAFISCHE MODELLE

- Kompakte Beschreibung von Abhängigkeiten zwischen Zufallsvariablen
- Informationsverarbeitung als Inferenz z.B. durch Nachrichtenaustausch zwischen benachbarten Knoten
- Mögliche Abstraktion neuronaler Informationsverarbeitung
- Viele Algorithmen des maschinellen Lernens können aus grafischen Modellen abgeleitet werden



ERINNERUNG: WAHRSCHEINLICHKEITSRECHNUNG

■ Zufallsvariablen: X, Y, Z

- Diskret: Verteilungen beschrieben durch Wahrscheinlichkeiten $p(X=\text{Wert})$
- Kontinuierlich: Verteilungen beschrieben durch Wahrscheinlichkeitsdichte $p(x)$

■ Gemeinsame Verteilung: $p(X, Y)$

■ Bedingte Verteilung: $$p(X | Y) = \frac{p(X, Y)}{p(Y)}$$

■ Produktregel: $$p(X, Y) = p(X | Y)p(Y)$$

■ Aussummieren: $$p(x) = \sum_y p(x, y) \qquad p(x) = \int_{-\infty}^{\infty} p(x, y) dy$$

UNABHÄNGIGKEIT VON ZUFALLSVARIABLEN

■ Unabhängigkeit:

- X, Y unabhängig g.d.w.: $p(X, Y) = p(X)p(Y)$
- Mit Produktregel $p(X, Y) = p(X | Y)p(Y)$
 - X, Y unabhängig g.d.w.: $p(X | Y) = p(X)$
 - X, Y unabhängig g.d.w.: $p(Y | X) = p(Y)$


■ Bedingte Unabhängigkeit:

- Anwendung der Unabhängigkeit auf $p(X, Y | Z)$
- X, Y unabhängig gegeben Z g.d.w. $p(X, Y | Z) = p(X | Z)p(Y | Z)$
- X, Y unabhängig gegeben Z g.d.w. $p(X | Y, Z) = p(X | Z)$
- X, Y unabhängig gegeben Z g.d.w. $p(Y | X, Z) = p(Y | Z)$

BEDINGTE UNABHÄNGIGKEIT


■ Interpretation:

- Sobald Z bekannt ist, sind die Variablen X und Y unabhängig.
- Bei Kenntnis von Z liefert X keinerlei zusätzliche Information über Y , und umgekehrt.




BEISPIEL FÜR BEDINGTE UNABHÄNGIGKEIT

- Das Jahreseinkommen hängt von der Schuhgröße ab.



BEISPIEL FÜR BEDINGTE UNABHÄNGIGKEIT

- Das Jahreseinkommen hängt von der Schuhgröße ab.
- Unterschied lässt sich jedoch durch die Variable „Geschlecht“ erklären.



BAYES-NETZE

- Ein Bayes-Netz **B** besteht aus
 - Einem **gerichteten, azyklischen Graphen $G=(V,E)$** , wobei die Knoten $V=\{V_1, \dots, V_n\}$ Zufallsvariablen sind.
 - Einer Menge **lokaler bedingter Wahrscheinlichkeitsverteilungen $P(V_j \mid pa(V_j))$** , $j=1, \dots, n$, wobei **$pa(V_j)$** die Elternknoten von V_j sind.
- **B** codiert eine gemeinsame Wahrscheinlichkeitsverteilung von (V_1, \dots, V_n) als Produkt der lokaler Wahrscheinlichkeiten


$$P(V_1 = v_1, \dots, V_n = v_n) = \prod_{j=1}^n P(V_j = v_j \mid pa(V_j) = v_{pa(V_j)})$$

BEISPIEL: NAIVE BAYES-ANNAHME

■ Naive Bayes-Annahme:


$$P(X_1, \dots, X_n \mid \omega) = \prod_{k=1}^n P(X_k \mid \omega)$$

$$P(X_1, \dots, X_n, \omega) = P(X_1, \dots, X_n \mid \omega) P(\omega) = P(\omega) \prod_{k=1}^n P(X_k \mid \omega)$$



BEISPIEL: MARKOV-KETTE

- Lineare Folge von Knoten:



$$P(X_1, \dots, X_n) = \prod_{j=1}^n P(X_j \mid pa(X_j)) = P(X_1) \cdot \prod_{j=2}^n P(X_j \mid X_{j-1})$$

- Interpretation: Die Variable X_j hängt nur von ihrer direkten Vorgängervariablen ab
- Markovketten werden oft zur Modellierung von Zustandsfolgen bzw. Zeitreihen X_1, \dots, X_n verwendet (j ist dann ein Zeitindex).

BEISPIEL: SPRINKLER-NETZWERK

$V = \{J, S, R, N\}$

$E = \{(J, S), (J, R),$
 $(S, N), (R, N)\}$

$pa(J) = \emptyset$

$P(J) = \begin{cases} 1/4 \text{ Frühling} \\ 1/4 \text{ Sommer} \\ 1/4 \text{ Herbst} \\ 1/4 \text{ Winter} \end{cases}$

$pa(S) = \{J\}$

S = Rasensprenger

$pa(R) = \{J\}$

R = Regen

$pa(N) = \{S, R\}$

N = NasserRasen

$$P(S | J) = \begin{matrix} J \setminus S & \text{an} & \text{aus} \\ \text{Frühling} & 0.1 & 0.9 \\ \text{Sommer} & 0.5 & 0.5 \\ \text{Herbst} & 0.1 & 0.9 \\ \text{Winter} & 0 & 1 \end{matrix}$$

$$P(R | J) = \begin{matrix} J \setminus R & \text{Regen} & \text{kein Regen} \\ \text{Frühling} & 0.3 & 0.7 \\ \text{Sommer} & 0.4 & 0.6 \\ \text{Herbst} & 0.2 & 0.8 \\ \text{Winter} & 0.1 & 0.9 \end{matrix}$$

$$P(N | S, R) = \begin{matrix} (S, R) \setminus N & \text{nass} & \text{trocken} \\ (\text{an}, \text{Regen}) & 1 & 0 \\ (\text{an}, \text{kein Regen}) & 1 & 0 \\ (\text{aus}, \text{Regen}) & 0.9 & 0.1 \\ (\text{aus}, \text{kein Regen}) & 0.01 & 0.99 \end{matrix}$$

SPRINKLER-NETZWERK II

- Die gemeinsame Verteilung von $\{J, S, R, N\}$ wird durch den Graphen und $3+4+4+4 = 15$ reelle Zahlen codiert:

$$pa(\cdot) = \begin{cases} J \mapsto \{ \} \\ S \mapsto \{ J \} \\ R \mapsto \{ J \} \\ N \mapsto \{ S, R \} \end{cases}$$

$$P(J) = \begin{cases} 1/4 & \text{Frühling} \\ 1/4 & \text{Sommer} \\ 1/4 & \text{Herbst} \\ 1/4 & \text{Winter} \end{cases}$$

$$P(S|J) = \begin{array}{c|cc} J \setminus S & \text{an} & \text{aus} \\ \hline \text{Frühling} & 0.1 & 0.9 \\ \text{Sommer} & 0.5 & 0.5 \\ \text{Herbst} & 0.1 & 0.9 \\ \text{Winter} & 0 & 1 \end{array}$$

$$P(R|J) = \begin{array}{c|cc} J \setminus R & \text{Regen} & \text{kein Regen} \\ \hline \text{Frühling} & 0.3 & 0.7 \\ \text{Sommer} & 0.4 & 0.6 \\ \text{Herbst} & 0.2 & 0.8 \\ \text{Winter} & 0.1 & 0.9 \end{array}$$

$$P(N|S, R) = \begin{array}{c|cc} (S, R) \setminus N & \text{nass} & \text{trocken} \\ \hline (\text{an}, \text{Regen}) & 1 & 0 \\ (\text{an}, \text{kein Regen}) & 1 & 0 \\ (\text{aus}, \text{Regen}) & 0.9 & 0.1 \\ (\text{aus}, \text{kein Regen}) & 0.01 & 0.99 \end{array}$$

$$P(J = j, S = s, R = r, N = n) =$$

$$P(N = n | S = s, R = r) \cdot P(S = s | J = j) \cdot P(R = r | J = j) \cdot P(J = j)$$

z.B. $P(J = \text{Sommer}, S = \text{aus}, R = \text{Regen}, N = \text{nass})$

$$= P(N = \text{nass} | S = \text{aus}, R = \text{Regen}) \cdot P(R = \text{Regen} | J = \text{Sommer})$$

$$\cdot P(S = \text{aus} | J = \text{Sommer}) \cdot P(J = \text{Sommer})$$

$$= 0.9 \cdot 0.4 \cdot 0.5 \cdot 0.25$$

$$= 0.045$$

KOMPAKTE DARSTELLUNG

- Die vollständige Festlegung der gemeinsamen Verteilung von $\{J, S, R, N\}$ in Form einer Wahrscheinlichkeitstabelle hätte $4 \cdot 2 \cdot 2 \cdot 2 - 1 = 31$ reelle Zahlen benötigt.
=> Exponentiell kompaktere Darstellung
- Notwendige Folge:
Nicht alle Wahrscheinlichkeitsverteilungen können mit diesem Bayes-Netz exakt codiert werden
- Aber: Jede Verteilung kann als Bayes-Netz dargestellt werden, es ist nur nicht klar, dass dieses klein ist.
- Ergo: Es gibt geschickte und ungeschickte Darstellungen als Bayes-Netz

BEISPIEL: ALARM-NETZWERK

■ Modelliertes Szenario

- Unser Haus in LA hat eine Alarmanlage.
- Wir sind im Urlaub. Unser Nachbar ruft an, falls er den Alarm hört. Wenn eingebrochen wurde, wollen wir zurück kommen.
- Leider ist der Nachbar nicht immer zu Hause.
- Leider geht die Alarmanlage auch bei kleinen Erdbeben los.

■ Fünf binäre Zufallsvariablen

- ⓑ Burglary – Einbruch hat stattgefunden
- ⓔ Earthquake – Erdbeben hat stattgefunden
- ⓐ Alarm – Alarmanlage geht los
- Ⓝ NeighborCalls – Nachbar ruft an
- Ⓡ RadioReport – Bericht über Erdbeben im Radio

ALARM: BEDINGTE UNABHÄNGIGKEITEN

■ Zerlegung in Faktoren nach Produktregel

$$p(B, E, A, N, R) = p(B)p(E | B)p(A | B, E)p(N | B, E, A)p(R | B, E, A, N)$$

- Geht immer, verschiedene Reihenfolgen möglich => Wir haben noch nichts gewonnen.

■ Annahme bedingter Unabhängigkeiten

$$p(E | B) = p(E)$$

Erdbeben hängt nicht von Einbruch ab

$$p(A | B, E) = p(A | B, E)$$

Alarm hängt von Einbruch und Erdbeben ab

$$p(N | B, E, A) = p(N | A)$$

Anruf von Nachbar hängt nur von Alarm ab

$$p(R | B, E, A, N) = p(R | E)$$

Nachricht im Radio hängt nur Erdbeben ab

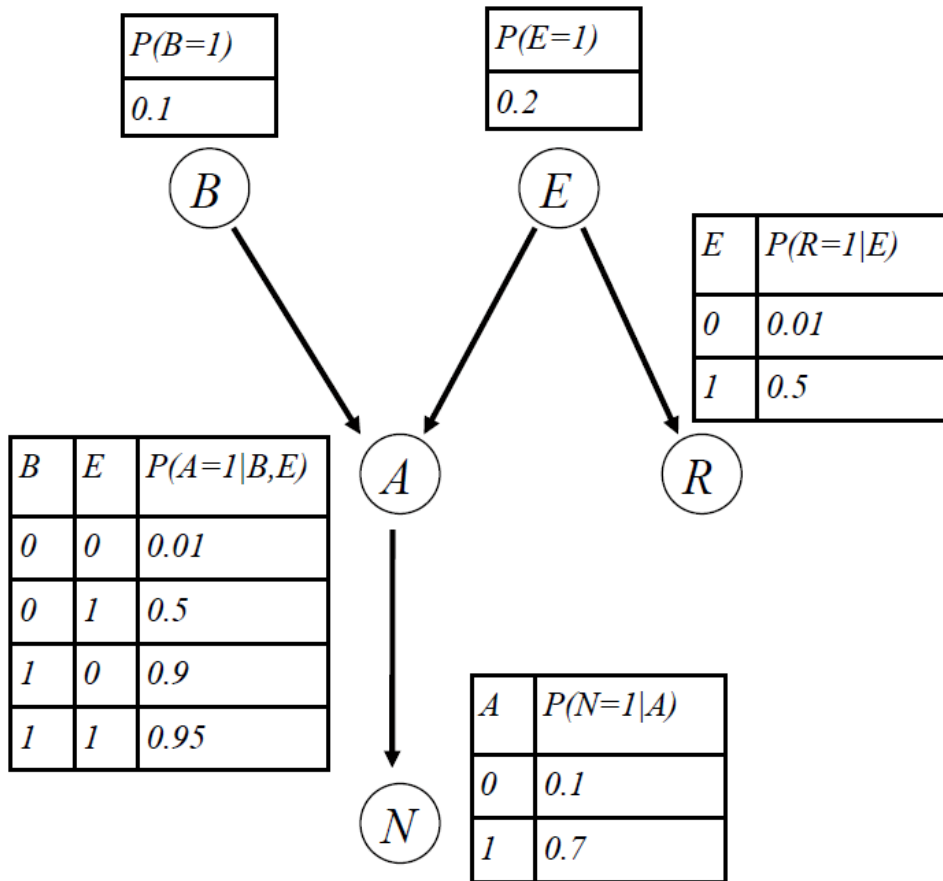
- Gewählte Reihenfolge ermöglicht es, diese Annahmen zu machen.

■ Vereinfachte Darstellung der Verbundverteilung

$$p(B, E, A, N, R) = p(B)p(E)p(A | E, B)p(N | A)p(R | E)$$


ALARM-NETZWERK: MODELLIERTE VERTEILUNG

$$p(B, E, A, N, R) = p(B)p(E)p(A | E, B)p(N | A)p(R | E)$$



UNABHÄNGIGKEIT: D-SEPARATION

- Menge einfacher Regeln, nach denen sich alle Unabhängigkeiten ableiten lassen
- „D“ steht für Directed, weil gerichteter Graph




$$p(B, E, A, N, R) =$$

$$p(B)p(E)p(A|E, B)p(N|A)p(R|E)$$


- Betrachte Pfad $A \leftarrow E \rightarrow R$
- Gilt $A \perp R | E$ (Unabhängigkeit von A und R gegeben E)?
- Ja, $p(A|R, E) = p(A|E)$
 $p(A|R, E) = p(A, R, E) / p(R, E) = \frac{p(A|E)p(R|E)p(E)}{p(R|E)p(E)}$
- Intuitiv:
 - Wenn wir schon wissen, dass ein Erdbeben eingetreten ist, wird die Wahrscheinlichkeit für Alarm nicht höher/niedriger durch RadioReport
 - Der divergierende Pfad $A \leftarrow E \rightarrow R$ wird durch Beobachtung von E blockiert

VERBINDUNGSMUSTER


■ Konvergenz bei Y



■ Serielle Verbindung bei Y




■ Divergenz bei Y




D-SEPARATION

■ Beispiele




Gilt $B \perp N \mid A$?

Ja.



Gilt $B \perp E \mid \emptyset$?


Ja.



Gilt $B \perp E \mid A$?

Nein!

D-SEPARATION



Gilt $B \perp\!\!\!\perp E \mid N$?


Nein.

- Ein Pfad ... X - Y - Z ... ist blockiert bei Y , wenn
 - Divergierende Verbindung und Y beobachtet, oder
 - Serielle Verbindung und Y beobachtet, oder
 - Konvergierende Verbindung und weder Y noch einer seiner Nachfahren beobachtet
 - Sonst ist der Pfad frei bei Y

- Ein Pfad ist insgesamt blockiert, wenn er bei einem auf dem Pfad liegenden Knoten blockiert ist

D-SEPARATION

- Seien X, Y, Z disjunkte Mengen von Zufallsvariablen.
- Definition: X und Y sind D-separiert durch Z g.d.w jeder Pfad von einem Knoten $X \in X$ zu einem Knoten $Y \in Y$ blockiert ist gegeben Z .
- Dann: $p(X|Y,Z) = p(X|Z)$ und $p(Y|X,Z) = p(Y|Z)$




Gilt $A \perp F | D$? Ja.

Gilt $B \perp E | C$? Nein: $B \rightarrow G \rightarrow E$

Gilt $A \perp E | C$? Nein: $A \rightarrow C \rightarrow B \rightarrow G \rightarrow E$

INFERENZ

- Gegeben: Beobachte Variablen \mathcal{X}^m (Evidenz $\{N, R\}$)
- Berechne Randverteilung über Anfrage-Variablen X^q ($\{B\}$), gegeben Evidenz
- Allgemeine Methode: Marginalisierung über restliche Variablen \mathcal{X}^r ($\{A, E\}$)




$$P(X^q, \mathcal{X}^m) = \sum_{\mathcal{X}^r} P(X_1, \dots, X_M) ; P(\mathcal{X}^m) = \sum_{\mathcal{X}^q} P(X^q, \mathcal{X}^m)$$

$$P(X^q | \mathcal{X}^m) = \frac{P(X^q, \mathcal{X}^m)}{P(\mathcal{X}^m)}$$

- Wahrscheinlichkeit für Einbruch ($B=1$) gegeben dass der Nachbar uns angerufen hat ($N=1$)?
 - Kein Radiobericht über Erdbeben:
 $p(B=1|N=1, R=0)=0.6$
 - Radiobericht über Erdbeben:
 $p(B=1|N=1, R=1)=0.2$

INFERENZ IN AZYKLISCHEN BAYES'SCHEN NETZEN



- Marginalisierung teuer
 - Summe hat exponentiell [in der Anzahl der unbeobachteten Variablen] viele Terme
- Nutze Struktur des Netzes für effiziente Marginalisierung!

BELIEF PROPAGATION

- Inferenz durch Nachrichtenaustausch zwischen benachbarten Knoten

- Nachrichten von Eltern zu Kindern

$$\pi_{Y_j}(x) = \left[\prod_{k \neq j} \lambda_{Y_k}(x) \right] \sum_{u_1, \dots, u_n} P(x|u_1, \dots, u_n) \prod_i \pi_X(u_i)$$


- Nachrichten von Kindern zu Eltern

$$\lambda_X(u_i) = \sum_x \left[\lambda(x) \sum_{u_k: k \neq i} P(x|u_1, \dots, u_n) \prod_{k \neq i} \pi_X(u_k) \right]$$
$$\lambda(x) = \prod_j \lambda_{Y_j}(x)$$

- Berechnung des Beliefs

$$\pi(x) = \sum_{u_1, \dots, u_n} P(x|u_1, \dots, u_n) \prod_i \pi_X(u_i)$$

$$Bel(x) = P(x|Evidence) = \frac{1}{Z} \lambda(x) \pi(x)$$



EXAKTE VS. APPROXIMATIVE INFERENZ

■ Exakte Inferenz

- Inferenz schwieriges Problem
- Allgemeine Bayes'sche Netze: Exakte Inferenz NP-hart
- Es gibt Algorithmen für exakte Inferenz in allgemeinen Bayes'schen Netzen, deren Laufzeit von den Eigenschaften der Graphstruktur abhängt (Message-Passing)

■ Techniken für approximative Inferenz

- Sampling
- Variationale Inferenz
- Expectation Propagation

ZUSAMMENFASSUNG GRAPHISCHE MODELLE

- Modellierung der Verbundverteilung einer Menge von Zufallsvariablen $\{X_1, \dots, X_N\}$

$$p(X_1, \dots, X_N) = \prod_{i=1}^N p(X_i \mid pa(X_i))$$

- Gerichteter azyklischer Graph drückt Unabhängigkeitsannahmen aus
- Kompakt, intuitiv verständlich
- Bedingte Unabhängigkeiten zwischen Variablenmengen können an der Graphstruktur abgelesen werden (D-Separation)
- Effiziente Inferenzalgorithmen nutzen Graphstruktur aus

KLAUSUR

- 20. Juli ~~15:00-17:00~~ im ~~HS 1+2~~ (~~Hörsaalzentrum, Endenicher Allee 19c~~)

Geändert: 12:00-14:00 im Wolfgang Paul-Hörsaal, Kreuzbergweg 28

- 90 Minuten Bearbeitungszeit
- Closed Book
- Testklausur ist im Verzeichnis <http://www.ais.uni-bonn.de/SS20/CI>